

LAPORAN MODUL 2

PRAKTIKUM PERMODELAN STATISTIKA



Disusun oleh :

Nama : IRVAN CAHYA NUGRAHA
NIM : 245410034
Kelas : IF-1

PROGRAM STUDI INFORMATIKA
PROGRAM SARJANA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TEKNOLOGI DIGITAL INDONESIA
YOGYAKARTA
2024/2025

LAPORAN PRAKTIKUM


MODUL 2

PENGELOLAAN DATA DENGAN R

A. PEMBAHASAN LISTING

Praktik

1. Praktik 1



```
# Praktik Impor File Excel di Google Colab

# 1. Instal dan muat paket readxl
cat("=== Menginstal dan Memuat Paket readxl ===\n")
install.packages("readxl")
library(readxl)

# 2. Membaca File Excel
# Menggunakan read_excel() dari paket readxl
cat("\n=== Membaca File Excel ===\n")
data <- read_excel("/content/Praktik2_1.xlsx", sheet = 1)
print(data)

=== Menginstal dan Memuat Paket readxl ===
Installing package into '/usr/local/lib/R/site-library'
(as 'lib' is unspecified)

=== Membaca File Excel ===
# A tibble: 10 × 2
  Nama    IPK
  <chr> <dbl>
1 Andi  3.6
2 Budi  3.4
3 Cici  3.3
4 Dodi  2.9
5 Ina   2.8
6 Rudi   3
7 Rini  2.4
8 Yani  1.9
9 Yuli  2.5
10 Val  2.8
```

Pembahasan : mengimpor file Excel (Praktik2_1.xlsx) yang sebelumnya diunggah secara manual ke Google Colab melalui panel Files. Setelah file tersimpan di direktori /content, proses dimulai dengan memasang paket readxl menggunakan perintah `install.packages("readxl")`, dan kemudian paket tersebut diaktifkan dengan `library(readxl)`. Fungsi inti yang digunakan adalah `read_excel("/content/Praktik2_1.xlsx", sheet = 1)` yang membaca data dari sheet pertama dan menyimpannya ke dalam variabel `data`. Fungsi `read_excel()` secara otomatis mendeteksi nama kolom seperti *Nama* dan *IPK* tanpa perlu konversi tambahan. Setelah data berhasil diimpor, perintah `print(data)` dijalankan untuk menampilkan isi dataset ke konsol. Praktik ini menekankan bahwa setiap analisis di R pada Google Colab wajib diawali dengan proses impor yang benar, dan file lokal harus diunggah terlebih dahulu setiap kali sesi baru dijalankan karena Colab tidak menyimpan file permanen.

2. Praktik 2

```
Q Perintah + Kode + Taks | Jalankan semua +
[7] / sa
# 1. Memuat dataset
data <- data.frame(
  id = c(1, 1, 2, 3, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18,
    19, 20, 21, 22, 23, 24, 25, 26, 27, 28),
  umur = c(19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38,
    39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56),
  pendapatan = c(4500, 5000, 5500, 6000, 6500, 7000, 7500, 8000, 8500, 9000, 9500, 1000, 1050, 1100,
    1150, 1200, 1250, 1300, 1350, 1400, 1450, 1500, 1550, 1600, 1650, 1700, 1750, 1800, 1850, 1900, 1950, 2000,
    2050, 2100, 2150, 2200, 2250, 2300, 2350, 2400, 2450, 2500, 2550, 2600, 2650, 2700, 2750, 2800, 2850, 2900, 2950, 3000,
    3050, 3100, 3150, 3200, 3250, 3300, 3350, 3400, 3450, 3500, 3550, 3600, 3650, 3700, 3750, 3800, 3850, 3900, 3950, 4000,
    4050, 4100, 4150, 4200, 4250, 4300, 4350, 4400, 4450, 4500, 4550, 4600, 4650, 4700, 4750, 4800, 4850, 4900, 4950, 5000,
    5050, 5100, 5150, 5200, 5250, 5300, 5350, 5400, 5450, 5500, 5550, 5600, 5650, 5700, 5750, 5800, 5850, 5900, 5950, 6000,
    6050, 6100, 6150, 6200, 6250, 6300, 6350, 6400, 6450, 6500, 6550, 6600, 6650, 6700, 6750, 6800, 6850, 6900, 6950, 7000,
    7050, 7100, 7150, 7200, 7250, 7300, 7350, 7400, 7450, 7500, 7550, 7600, 7650, 7700, 7750, 7800, 7850, 7900, 7950, 8000,
    8050, 8100, 8150, 8200, 8250, 8300, 8350, 8400, 8450, 8500, 8550, 8600, 8650, 8700, 8750, 8800, 8850, 8900, 8950, 9000,
    9050, 9100, 9150, 9200, 9250, 9300, 9350, 9400, 9450, 9500, 9550, 9600, 9650, 9700, 9750, 9800, 9850, 9900, 9950, 10000),
  kategori = c("PNS", "PNS", "Swasta", "Miraswaha", "Miraswaha", "PNS",
    "Swasta", "PNS", "Miraswaha", "Swasta", "PNS", "Swasta",
    "PNS", "Miraswaha", "Swasta", "PNS", "Miraswaha", "Swasta",
    "PNS", "Swasta", "Miraswaha", "PNS", "Swasta", "Miraswaha",
    "PNS", "Swasta", "Miraswaha", "PNS", "Swasta", "Miraswaha",
    "PNS", "Swasta", "PNS", "Miraswaha", "Swasta", "PNS")
)

# 2. Memeriksa Data

# a. Melihat data secara umum
cat("== a. Melihat Data Secara Umum ==\n")
cat("Nama data:\n")
print(data)
cat("Dimensi (s baris portasi):\n")
print(nrow(data))
cat("Head data:\n")
print(head(data))
cat("Tail (s baris terakhir):\n")
print(tail(data))

# b. Memeriksa struktur data
cat("== b. Memeriksa Struktur Data ==\n")
str(data)

# c. Memeriksa dimensi data
cat("== c. Memeriksa Dimensi Data ==\n")
cat("Dimensi (baris, kolom):\n", dim(data), "\n")
cat("Jumlah baris:\n", nrow(data), "\n")
cat("Jumlah kolom:\n", ncol(data), "\n")
cat("Nama kolom:\n", names(data), "\n")

# d. Ringkasan statistik
cat("== d. Ringkasan Statistik ==\n")
summary(data)

# e. Mengecek nilai hilang
cat("== e. Mengecek Nilai Hilang ==\n")
cat("Jumlah NA per kolom:\n")
print(colSums(is.na(data)))
cat("Jumlah baris lengkap (tampa NA):\n", sum(complete.cases(data)), "\n")

# 3. Menghapus Duplikat
cat("== 3. Menghapus Duplikat ==\n")
cat("Jumlah baris duplikat:\n", sum(duplicated(data)), "\n")
cat("Baris duplikat:\n")
print(data[duplicated(data), ])

# 4. Menghapus Outlier pada pendapatan
cat("== 4. Menghapus Outlier pada pendapatan ==\n")
Q1 <- quantile(datapendapatan, 0.25, na.rm = TRUE)
Q3 <- quantile(datapendapatan, 0.75, na.rm = TRUE)
IQR <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR
upper_bound <- Q3 + 1.5 * IQR
cat("Batas bawah (Q1 - 1.5 * IQR):\n", lower_bound, "\n")
cat("Batas atas (Q3 + 1.5 * IQR):\n", upper_bound, "\n")
outliers <- datapendapatan[datapendapatan < lower_bound |
  datapendapatan > upper_bound & !is.na(datapendapatan)]
cat("Nilai outlier pada pendapatan:\n", outliers, "\n")

== a. Melihat Data Secara Umum ==
Nama data:
  id umur pendapatan kategori
1  1  25      5000      PNS
2  1  25      5000      PNS
3  2  30      6000  Swasta
4  3  33      6500 Miraswaha
5  3  33      6500 Miraswaha
6  4  35      7000      PNS
7  8  38      7500  Swasta
8  6  40      8000      PNS
9  7  43      8200 Miraswaha
10 8  27      NA  Swasta
11 9  29      8500      PNS
12 10 NA      8900  Swasta
13 12 41      9200      PNS
14 12 36      9300 Miraswaha
15 13 38      9800  Swasta
16 14 45      9900      PNS
17 15 23      4700 Miraswaha
18 16 39      5300  Swasta
19 17 34      6100      PNS
20 16 36      7200  Swasta
21 19 41      NA Miraswaha
22 20 27      5400      PNS
23 23 38      4500      PNS
24 22 32      4800 Miraswaha
25 23 NA      5100      PNS
26 24 28      5900  Swasta
27 25 39      7800      PNS
28 26 34      6600 Miraswaha
29 27 35      4700  Swasta
30 28 38      10000      PNS
```

```
id umur pendapatan kategori
1 1 25 5000 PNS
2 1 25 5000 PNS
3 2 30 6000 Swasta
4 3 22 4500 Wirausaha
5 3 22 4500 Wirausaha
6 4 35 7000 PNS

Tail (6 baris terakhir):
id umur pendapatan kategori
25 23 NA 5100 PNS
26 24 28 5900 Swasta
27 25 39 7800 PNS
28 26 24 4600 Wirausaha
29 27 31 6700 Swasta
30 28 50 15000 PNS

=== b. Periksa Struktur Data ===
'data.frame': 30 obs. of 4 variables:
 $ id : num 1 1 2 3 3 4 5 6 7 8 ...
 $ umur : num 25 25 30 22 22 35 28 40 33 27 ...
 $ pendapatan : num 5000 5000 6000 4500 4500 7000 5500 8000 6200 NA ...
 $ kategori : chr "PNS" "PNS" "Swasta" "Wirausaha" ...

=== c. Periksa Dimensi Data ===
Dimensi (baris, kolom): 30 4
Jumlah baris: 30
Jumlah kolom: 4
Nama kolom: id umur pendapatan kategori

=== d. Ringkasan Statistik ===
id umur pendapatan kategori
Min. : 1.00 Min. :22.00 Min. : 4500 Length:30
1st Qu.: 6.25 1st Qu.:26.75 1st Qu.: 5000 Class :character
Median :13.50 Median :30.00 Median : 5700 Mode :character
Mean :13.67 Mean :31.43 Mean : 6261
3rd Qu.:20.75 3rd Qu.:35.25 3rd Qu.: 6850
Max. :28.00 Max. :50.00 Max. :15000
NA's :2 NA's :2

=== e. Mengecek Nilai Hilang ===
Jumlah NA per kolom:
id umur pendapatan kategori
0 2 2 0
Jumlah baris lengkap (tanpa NA): 26

=== f. Mengecek Duplikat ===
Jumlah baris duplikat: 2
Baris duplikat:
id umur pendapatan kategori
2 1 25 5000 PNS
5 3 22 4500 Wirausaha

=== g. Mengecek Outlier ===
Batas bawah (Q1 - 1.5 * IQR): 2225
Batas atas (Q3 + 1.5 * IQR): 9625
Nilai outlier pada pendapatan: NA NA 15000
```

Pembahasan : Pada praktik ini dilakukan pemeriksaan kualitas dataset untuk memahami kondisi awal data. Fungsi head() dan tail() digunakan untuk menampilkan contoh baris teratas dan terbawah agar mengetahui pola isi data. Struktur data dicek menggunakan str() untuk melihat tipe variabel (numeric, character) dan memastikan setiap kolom sesuai. Selanjutnya dim(), nrow(), dan ncol() digunakan untuk mengetahui ukuran dataset, sedangkan names() menampilkan nama kolom. Ringkasan statistik dengan summary() mendeteksi rentang nilai serta keberadaan nilai ekstrem. Data hilang dianalisis memakai colSums(is.na(data)) dan complete.cases() untuk menghitung baris lengkap. Pemeriksaan data duplikat dilakukan dengan duplicated(data) untuk mengetahui apakah terdapat entri ganda. Outlier pada kolom numerik seperti pendapatan dihitung menggunakan metode IQR (Q1, Q3, IQR, batas bawah/atas) untuk mengidentifikasi nilai yang menyimpang secara signifikan dari distribusi data.

3. Praktik 3

```
modul2.ipynb
File Edit Lihat Sisipkan Runtime Fitur Bantuan

Perintah + Kode + Teks ▶ Jalankan semua

[8]
✓ 1d

# 1. Membuat dataset
data <- data.frame(
  id = c(1, 1, 2, 3, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18,
        19, 20, 21, 22, 23, 24, 25, 26, 27, 28),
  umur = c(25, 25, 30, 22, 22, 35, 28, 40, 33, 27, 29, NA, 31, 26, 38, 45, 23,
          29, 34, 36, 41, 27, 30, 32, NA, 28, 39, 24, 31, 50),
  pendapatan = c(5000, 5000, 6000, 4500, 4500, 7000, 5500, 8000, 6200, NA,
                5100, 4900, 7500, 5200, 6800, 9000, 4700, 5300, 6100, 7200,
                NA, 5400, 6500, 4800, 5100, 5900, 7800, 4600, 6700, 15000),
  kategori = c("PNS", "PNS", "Swasta", "Wirausaha", "Wirausaha", "PNS",
               "Swasta", "PNS", "Wirausaha", "Swasta", "PNS", "Swasta",
               "PNS", "Wirausaha", "Swasta", "PNS", "Wirausaha", "Swasta",
               "PNS", "Swasta", "Wirausaha", "PNS", "Swasta", "Wirausaha",
               "PNS", "Swasta", "PNS", "Wirausaha", "Swasta", "PNS")
)
print(data)

# Muat paket yang diperlukan
library(dplyr)
library(ggplot2)

# 2. Persiapan Data

# a. Menangani nilai hilang
cat("=== a. Menangani Nilai Hilang ===\n")
# Cek jumlah NA
cat("Jumlah NA per kolom sebelum penanganan:\n")
print(colSums(is.na(data)))

# Opsi 1: Menghapus baris yang ada NA
data_no_na <- na.omit(data)
cat("\nOpsi 1 menghapus baris yang ada NA\n")
cat("Jumlah baris setelah menghapus NA:", nrow(data_no_na), "\n")

# Opsi 2: Mengisi NA dengan median untuk umur dan pendapatan
data_imputed <- data
data_imputed$umur[is.na(data_imputed$umur)] <- median(data_imputed$umur, na.rm = TRUE)
data_imputed$pendapatan[is.na(data_imputed$pendapatan)] <- median(data_imputed$pendapatan, na.rm = TRUE)
cat("\nOpsi 2 Mengisi NA dengan median untuk umur dan pendapatan\n")
cat("Jumlah NA per kolom setelah imputasi:\n")
print(colSums(is.na(data_imputed)))
cat("Jumlah baris setelah mengisi NA dengan median:", nrow(data_imputed), "\n")

# b. Menghapus data duplikat
cat("\n=== b. Menghapus Data Duplikat ===\n")
cat("Jumlah baris duplikat:", sum(duplicated(data_imputed)), "\n")
data_no_duplicates <- distinct(data_imputed)
cat("Jumlah baris setelah menghapus duplikat:", nrow(data_no_duplicates), "\n")

# c. Memastikan tipe data sesuai
cat("\n=== c. Memastikan Tipe Data Sesuai ===\n")
# Cek tipe data
cat("Tipe data sebelum konversi:\n")
print(str(data_no_duplicates))

# Konversi tipe data
data_no_duplicates$kategori <- as.factor(data_no_duplicates$kategori)
data_no_duplicates$umur <- as.numeric(data_no_duplicates$umur)
data_no_duplicates$pendapatan <- as.numeric(data_no_duplicates$pendapatan)
cat("Tipe data setelah konversi:\n")
print(str(data_no_duplicates))

# d. Menangani outlier (Metode IQR)
cat("\n=== d. Menangani Outlier ===\n")
Q1 <- quantile(data_no_duplicates$pendapatan, 0.25, na.rm = TRUE)
Q3 <- quantile(data_no_duplicates$pendapatan, 0.75, na.rm = TRUE)
IQR <- Q3 - Q1
```



modul2.ipynb



File Edit Lihat Sisipkan Runtime Fitur Bantuan

Q Perintah + Kode + Teks ▶ Jalankan semua ▼

[8]
✓ 1d

```
cat("Batas atas:", upper_bound, "\n")

# Identifikasi outlier
outliers <- data_no_duplicates$pendapatan[data_no_duplicates$pendapatan < lower_bound |
                                           data_no_duplicates$pendapatan > upper_bound]
cat("Nilai outlier pada pendapatan:", outliers, "\n")

# Hapus outlier
data_no_outliers <- filter(data_no_duplicates,
                           pendapatan >= lower_bound & pendapatan <= upper_bound)
cat("Jumlah baris setelah menghapus outlier:", nrow(data_no_outliers), "\n")

# e. Membuat variabel baru
cat("\n=== e. Membuat Variabel Baru ===\n")
data_with_new_var <- mutate(data_no_outliers,
                             log_pendapatan = log(pendapatan), # Transformasi log
                             umur_kategori = case_when(
                               umur < 30 ~ "Muda",
                               umur >= 30 & umur < 40 ~ "Dewasa",
                               TRUE ~ "Lansia"
                             ))
cat("Beberapa baris dengan variabel baru:\n")
print(head(data_with_new_var))

# f. Memfilter data
cat("\n=== f. Memfilter Data ===\n")
data_filtered <- filter(data_with_new_var,
                        umur >= 18,
                        kategori %in% c("PNS", "Swasta"))
cat("Jumlah baris setelah memfilter (umur >= 18, kategori PNS/Swasta):",
    nrow(data_filtered), "\n")
print(head(data_filtered))

# Simpan data yang sudah disiapkan
write.csv(data_filtered, "data_prepared.csv", row.names = FALSE)
cat("Data disimpan sebagai 'data_prepared.csv'\n")
```



	id	umur	pendapatan	kategori
1	1	25	5000	PNS
2	1	25	5000	PNS
3	2	30	6000	Swasta
4	3	22	4500	Wirausaha
5	3	22	4500	Wirausaha
6	4	35	7000	PNS
7	5	28	5500	Swasta
8	6	40	8000	PNS
9	7	33	6200	Wirausaha
10	8	27	NA	Swasta
11	9	29	5100	PNS
12	10	NA	4900	Swasta
13	11	31	7500	PNS
14	12	26	5200	Wirausaha
15	13	38	6800	Swasta
16	14	45	9000	PNS
17	15	23	4700	Wirausaha
18	16	29	5300	Swasta
19	17	34	6100	PNS
20	18	36	7200	Swasta
21	19	41	NA	Wirausaha
22	20	27	5400	PNS
23	21	30	6500	Swasta
24	22	32	4800	Wirausaha
25	23	NA	5100	PNS
26	24	28	5900	Swasta
27	25	39	7800	PNS
28	26	24	4600	Wirausaha
29	27	31	6700	Swasta
30	28	50	15000	PNS

```

id      umur pendapatan kategori
0      2      2      0

Opsi 1 menghapus baris yang ada NA
Jumlah baris setelah menghapus NA: 26

Opsi 2 Mengisi NA dengan median untuk umur dan pendapatan
Jumlah NA per kolom setelah imputasi:
id      umur pendapatan kategori
0      0      0      0
Jumlah baris setelah mengisi NA dengan median: 30

=== b. Menghapus Data Duplikat ===
Jumlah baris duplikat: 2
Jumlah baris setelah menghapus duplikat: 28

=== c. Memastikan Tipe Data Sesuai ===
Tipe data sebelum konversi:
'data.frame': 28 obs. of 4 variables:
 $ id      : num  1 2 3 4 5 6 7 8 9 10 ...
 $ umur    : num  25 30 22 35 28 40 33 27 29 30 ...
 $ pendapatan: num  5000 6000 4500 7000 5500 8000 6200 5700 5100 4900 ...
 $ kategori : chr  "PNS" "Swasta" "Wirausaha" "PNS" ...
NULL
Tipe data setelah konversi:
'data.frame': 28 obs. of 4 variables:
 $ id      : num  1 2 3 4 5 6 7 8 9 10 ...
 $ umur    : num  25 30 22 35 28 40 33 27 29 30 ...
 $ pendapatan: num  5000 6000 4500 7000 5500 8000 6200 5700 5100 4900 ...
 $ kategori : Factor w/ 3 levels "PNS","Swasta",...: 1 2 3 1 2 1 3 2 1 2 ...
NULL

=== d. Menangani Outlier ===
Batas bawah: 2475
Batas atas: 9475
Nilai outlier pada pendapatan: 15000
Jumlah baris setelah menghapus outlier: 27

=== e. Membuat Variabel Baru ===
Beberapa baris dengan variabel baru:
id umur pendapatan kategori log_pendapatan umur_kategori
1 1 25 5000 PNS 8.517193 Muda
2 2 30 6000 Swasta 8.699515 Dewasa
3 3 22 4500 Wirausaha 8.411833 Muda
4 4 35 7000 PNS 8.853665 Dewasa
5 5 28 5500 Swasta 8.612503 Muda
6 6 40 8000 PNS 8.987197 Lansia

=== f. Memfilter Data ===
Jumlah baris setelah memfilter (umur >= 18, kategori PNS/Swasta): 20
id umur pendapatan kategori log_pendapatan umur_kategori
1 1 25 5000 PNS 8.517193 Muda
2 2 30 6000 Swasta 8.699515 Dewasa
3 4 35 7000 PNS 8.853665 Dewasa
4 5 28 5500 Swasta 8.612503 Muda
5 6 40 8000 PNS 8.987197 Lansia
6 8 27 5700 Swasta 8.648221 Muda
Data disimpan sebagai 'data_prepared.csv'

```

Pembahasan : Pada tahap pembersihan, baris dengan nilai hilang (NA) dihapus menggunakan `na.omit(data)` atau `data[complete.cases(data), ]`, memastikan hanya observasi lengkap yang digunakan. Duplikat data dihilangkan memakai `unique(data)` atau `data[!duplicated(data), ]` untuk mencegah perhitungan ganda yang mengganggu analisis. Jika ditemukan outlier berdasarkan perhitungan batas IQR, penanganan dapat dilakukan dengan menghapus atau memisah nilai ekstrem menggunakan kondisi logis seperti `data <- data[data$pendapatan <= upper_bound & data$pendapatan >= lower_bound, ]`. Setelah proses pembersihan, dataset diperiksa ulang dengan `summary()` dan `str()` untuk memastikan tidak ada lagi NA, duplikat, atau nilai menyimpang. Hasil akhir adalah dataset yang lebih konsisten, siap digunakan untuk analisis atau pemodelan lanjutan.

Latihan

1. Latihan 1

```
[11] # Memeriksa struktur data
# O d print("=== Struktur Data ===")
str(data)

# Memeriksa dimensi data (jumlah baris dan kolom)
print("=== Dimensi Data ===")
dim(data)


# Memeriksa ringkasan data
print("=== Ringkasan Data ===")
summary(data)

# Memeriksa data hilang
print("=== Data Hilang ===")
colSums(is.na(data))

# Memeriksa data duplikat
print("=== Data Duplikat ===")
sum(duplicated(data))

# Memeriksa outlier (contoh sederhana menggunakan boxplot untuk beberapa kolom numerik)
# Anda mungkin perlu menyesuaikan kolom yang ingin diperiksa
print("=== Memeriksa Outlier (dengan Boxplot) ===")
boxplot(data$longitude,      main = "Boxplot Longitude")
boxplot(data$latitude,      main = "Boxplot Latitude")
boxplot(data$housing_median_age, main = "Boxplot Housing Median Age")
boxplot(data$total_rooms,    main = "Boxplot Total Rooms")
boxplot(data$total_bedrooms, main = "Boxplot Total Bedrooms")
boxplot(data$population,     main = "Boxplot Population")
boxplot(data$households,     main = "Boxplot Households")
boxplot(data$median_income,  main = "Boxplot Median Income")
boxplot(data$median_house_value, main = "Boxplot Median House Value")
```

```
[1] "=== Struktur Data ==="
'data.frame':  3000 obs. of  9 variables:
 $ longitude   : num  -122 -118 -118 -118 -120 ...
 $ latitude    : num   37.4 34.3 33.8 33.8 36.3 ...
 $ housing_median_age: num   27 43 27 28 19 37 43 19 15 31 ...
 $ total_rooms  : num  3885 1518 3589 67 1241 ...
 $ total_bedrooms: num   661 318 587 15 244 213 225 471 617 632 ...
 $ population   : num  1537 809 1484 49 850 ...
 $ households   : num   686 277 495 11 237 284 218 441 599 603 ...
 $ median_income : num   6.61 3.6 5.79 6.14 2.94 ...
 $ median_house_value: num  344708 176500 278500 330000 81700 ...
[1] "=== Dimensi Data ==="
3000 9
[1] "=== Ringkasan Data ==="
      longitude      latitude  housing_median_age  total_rooms
Min.   :-124.2   Min.   :32.56   Min.   : 1.00   Min.   : 6
1st Qu.: -121.8 1st Qu.:33.93   1st Qu.:18.00   1st Qu.:1481
Median :-118.5 Median :34.27   Median :29.00   Median :2186
Mean   :-119.6 Mean   :35.64   Mean   :28.85   Mean   :2600
3rd Qu.: -118.8 3rd Qu.:37.69   3rd Qu.:37.00   3rd Qu.:3129
Max.    :-114.5 Max.    :41.92   Max.    :52.00   Max.   :38458
total_bedrooms  population  households  median_income
Min.   : 2   Min.   : 5   Min.   : 2.0   Min.   : 0.4999
1st Qu.:291 1st Qu.: 780 1st Qu.:273.0 1st Qu.: 2.5448
Median :437 Median :1155 Median :409.5 Median : 3.4872
Mean   :538 Mean   :1483 Mean   :489.9 Mean   : 3.8073
3rd Qu.:636 3rd Qu.:1743 3rd Qu.:597.2 3rd Qu.: 4.0565
Max.   :5419 Max.   :11935 Max.   :4938.0 Max.   :15.0001
median_house_value
Min.   : 22500
1st Qu.:121200
Median :177650
Mean   :209546
3rd Qu.:263975
Max.   :500001
[1] "=== Data Hilang ==="
longitude: 0 latitude: 0 housing_median_age: 0 total_rooms: 0 total_bedrooms: 0 population: 0 households: 0 median_income: 0 median_house_value: 0
[1] "=== Data Duplikat ==="
0
[1] "=== Memeriksa Outlier (dengan Boxplot) ==="
```



A boxplot titled "Boxplot Longitude" showing the distribution of longitude values. The y-axis ranges from -125 to -115. The box represents the interquartile range (IQR) from approximately -121.8 to -118.5, with a median line at -119.6. The whiskers extend from the box edges to the minimum value of -124.2 and the maximum value of -114.5. There are no outliers shown.

```
[15]
✓ Od
# Menghapus baris dengan data hilang (NA)
# data_cleaned akan berisi data tanpa baris dengan nilai NA di kolom manapun
data_cleaned <- na.omit(data)

print("=== Jumlah Baris Setelah Menghapus Data Hilang ===")
print(nrow(data_cleaned))

# Menghapus data duplikat
# data_final akan berisi data tanpa baris yang duplikat
data_final <- unique(data_cleaned)

print("=== Jumlah Baris Setelah Menghapus Data Duplikat ===")
print(nrow(data_final))

[1] "=== Jumlah Baris Setelah Menghapus Data Hilang ==="
[1] 3000
[1] "=== Jumlah Baris Setelah Menghapus Data Duplikat ==="
[1] 3000
```

```
[9]
✓ Od
print("\n=== Membaca File CSV ===")
# Use read.csv to read the CSV file
data = read.csv("/content/sample_data/california_housing_test.csv")
# Display only the first 6 rows of the data
print(head(data, 6))

[1] "\n=== Membaca File CSV ==="
  longitude latitude housing_median_age total_rooms total_bedrooms population
1    -122.05    37.37             27         3885           661         1537
2    -118.30    34.26             43         1510           310          809
3    -117.81    33.78             27         3589           507         1484
4    -118.36    33.82             28           67            15           49
5    -119.67    36.33             19         1241           244          850
6    -119.56    36.51             37         1018           213          663
 households median_income median_house_value
1         606         6.6085         344700
2         277         3.5990         176500
3         495         5.7934         270500
4          11         6.1359         330000
5         237         2.9375          81700
6         204         1.6635          67000
```

Pembahasan : `read.csv("sample_data/california_housing_test.csv")` yang disimpan ke dalam variabel, misalnya `data`. Fungsi `read.csv()` digunakan secara khusus untuk membaca file dengan format CSV dan secara otomatis mengubah setiap kolom menjadi bentuk data frame di R. Setelah dataset berhasil dimuat, langkah berikutnya adalah menampilkan enam baris awal menggunakan fungsi `head(data, 6)`. Penggunaan `head()` dengan argumen 6 bertujuan untuk memastikan struktur awal dataset dapat dilihat, seperti nama kolom, nilai numerik awal, dan mendeteksi apakah terdapat nilai aneh atau kosong sejak awal. Setelah baris awal terlihat, dilakukan pemeriksaan struktur data dengan `str(data)` untuk mengecek tipe data dari setiap kolom, apakah berupa integer, numeric, atau factor. Kemudian dilanjutkan dengan fungsi `dim(data)` untuk melihat dimensi dataset, yaitu jumlah baris dan jumlah kolom yang tersedia. Ringkasan statistik dari setiap kolom diperiksa menggunakan `summary(data)` yang menampilkan nilai minimum, maksimum, mean, median, dan quartile dari data numerik seperti `median_income` atau `housing_median_age`. Pemeriksaan data hilang dilakukan dengan fungsi `anyNA(data)` atau `sum(is.na(data))`, jika hasilnya lebih dari nol berarti terdapat missing value di salah satu kolom. Data duplikat diperiksa menggunakan `duplicated(data)` dan `sum(duplicated(data))` untuk mengetahui

apakah ada baris yang muncul lebih dari satu kali. Sedangkan untuk deteksi outlier secara awal masih dilakukan secara manual melalui nilai ekstrim dari `summary(data)` atau menggunakan fungsi seperti `boxplot(data$median_house_value)` jika ingin melihat nilai lonjakan ekstrem secara visual.

2. Latihan 2

Pembahasan :

B. PEMBAHASAN TUGAS

1. Tugas 1

Pembahasan :

C. KESIMPULAN

D. LAMPIRAN

NIM : 245410034

Nama : Irvan Cahya Nugraha

Kelas : IF-1

LISTING PRAKTIKUM STATISTIKA MODUL