

LAPORAN MODUL 3

PRAKTIKUM PERMODELAN STATISTIKA



Disusun oleh :

Nama : IRVAN CAHYA NUGRAHA
NIM : 245410034
Kelas : IF-1

PROGRAM STUDI INFORMATIKA
PROGRAM SARJANA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TEKNOLOGI DIGITAL INDONESIA
YOGYAKARTA
2024/2025

LAPORAN PRAKTIKUM


MODUL 2

PENGELOLAAN DATA DENGAN R

A. PEMBAHASAN LISTING


Praktik

1. Praktik 1




Pembahasan : mengimpor file Excel (Praktik2_1.xlsx) yang sebelumnya diunggah secara manual ke Google Colab melalui panel Files. Setelah file tersimpan di direktori /content, proses dimulai dengan memasang paket readxl menggunakan perintah `install.packages("readxl")`, dan kemudian paket tersebut diaktifkan dengan `library(readxl)`. Fungsi inti yang digunakan adalah `read_excel("/content/Praktik2_1.xlsx", sheet = 1)` yang membaca data dari sheet pertama dan menyimpannya ke dalam variabel `data`. Fungsi `read_excel()` secara otomatis mendeteksi nama kolom seperti *Nama* dan *IPK* tanpa perlu konversi tambahan. Setelah data berhasil diimpor, perintah `print(data)` dijalankan untuk menampilkan isi dataset ke konsol. Praktik ini menekankan bahwa setiap analisis di R pada Google Colab wajib diawali dengan proses impor yang benar, dan file lokal harus diunggah terlebih dahulu setiap kali sesi baru dijalankan karena Colab tidak menyimpan file permanen.

2. Praktik 2



Pembahasan : Pada praktik ini dilakukan pemeriksaan kualitas dataset untuk memahami kondisi awal data. Fungsi `head()` dan `tail()` digunakan untuk menampilkan contoh baris teratas dan terbawah agar mengetahui pola isi data. Struktur data dicek menggunakan `str()` untuk melihat tipe variabel (numeric, character) dan memastikan setiap kolom sesuai. Selanjutnya `dim()`, `nrow()`, dan `ncol()` digunakan untuk mengetahui ukuran dataset, sedangkan `names()` menampilkan nama kolom. Ringkasan statistik dengan `summary()` mendeteksi rentang nilai serta keberadaan nilai ekstrem. Data hilang dianalisis memakai `colSums(is.na(data))` dan `complete.cases()` untuk menghitung baris lengkap. Pemeriksaan data duplikat dilakukan dengan `duplicated(data)` untuk mengetahui apakah terdapat entri ganda. Outlier pada kolom numerik seperti pendapatan dihitung menggunakan metode IQR (Q1, Q3, IQR, batas bawah/atas) untuk mengidentifikasi nilai yang menyimpang secara signifikan dari distribusi data.


3. Praktik 3



Pembahasan : Pada tahap pembersihan, baris dengan nilai hilang (NA) dihapus menggunakan `na.omit(data)` atau `data[complete.cases(data), ]`, memastikan hanya observasi lengkap yang digunakan. Duplikat data dihilangkan memakai `unique(data)` atau `data[!duplicated(data), ]` untuk mencegah perhitungan ganda yang mengganggu analisis. Jika ditemukan outlier berdasarkan perhitungan batas IQR, penanganan dapat dilakukan dengan menghapus atau memisah nilai ekstrem menggunakan kondisi logis seperti `data <- data[data$pendapatan <= upper_bound & data$pendapatan >= lower_bound, ]`. Setelah proses pembersihan, dataset diperiksa ulang dengan `summary()` dan `str()` untuk memastikan tidak ada lagi NA, duplikat, atau nilai menyimpang. Hasil akhir adalah dataset yang lebih konsisten, siap digunakan untuk analisis atau pemodelan lanjutan.

Latihan

1. Latihan 1



Pembahasan : `read.csv("sample_data/california_housing_test.csv")` yang disimpan ke dalam variabel, misalnya `data`. Fungsi `read.csv()` digunakan secara khusus untuk membaca file dengan format CSV dan secara otomatis mengubah setiap kolom menjadi bentuk data frame di R. Setelah dataset berhasil dimuat, langkah berikutnya adalah menampilkan enam baris awal menggunakan fungsi `head(data, 6)`. Penggunaan `head()` dengan argumen 6 bertujuan untuk memastikan struktur awal dataset dapat dilihat, seperti nama kolom, nilai numerik awal, dan mendeteksi apakah terdapat nilai aneh atau kosong sejak awal. Setelah baris awal terlihat, dilakukan pemeriksaan struktur data dengan `str(data)` untuk mengecek tipe data dari setiap kolom, apakah berupa integer, numeric, atau factor. Kemudian dilanjutkan dengan fungsi `dim(data)` untuk melihat dimensi dataset, yaitu jumlah baris dan jumlah kolom yang tersedia. Ringkasan statistik dari setiap kolom diperiksa menggunakan `summary(data)` yang menampilkan nilai minimum, maksimum, mean, median, dan quartile dari data numerik seperti `median_income` atau `housing_median_age`. Pemeriksaan data hilang dilakukan dengan fungsi `anyNA(data)` atau `sum(is.na(data))`, jika hasilnya lebih dari nol berarti terdapat missing value di salah satu kolom. Data duplikat diperiksa menggunakan `duplicated(data)` dan `sum(duplicated(data))` untuk mengetahui

apakah ada baris yang muncul lebih dari satu kali. Sedangkan untuk deteksi outlier secara awal masih dilakukan secara manual melalui nilai ekstrim dari summary(data) atau menggunakan fungsi seperti boxplot(data\$median_house_value) jika ingin melihat nilai lonjakan ekstrem secara visual.

2. Latihan 2

Pembahasan :

B. PEMBAHASAN TUGAS

1. Tugas 1

```
## 1. Import Dataset ##
advertising <- read.csv("advertising.csv")

# Lihat struktur data
str(advertising)

## 2. Statistik Deskriptif (Optional tapi bagus untuk analisis) ##
summary(advertising)

## 3. Model Regresi Linier Sederhana: TV -> Sales ##
model <- lm(Sales ~ TV, data = advertising)

# Tampilkan ringkasan model
summary(model)


## 4. Plot Regresi (Visualisasi) ##
plot(advertising$TV, advertising$Sales,
     main = "Regresi Linier: TV vs Sales",
     xlab = "Ruang Iklan TV",
     ylab = "Penjualan",
     abline(model, lwd = 2))

## 5. Prediksi Contoh ##
prediksi <- data.frame(TV = c(50, 100, 150))
predict(model, prediksi)

## 'data.frame': 200 obs. of 4 variables:
 $ TV      : num  230.1 44.5 17.2 151.5 100.8 ...
 $ Radio   : num  37.8 39.3 45.9 41.3 10.8 48.9 32.8 19.6 2.3 2.6 ...
 $ Newspaper: num  62.2 49.1 89.3 38.5 58.4 75 23.5 11.6 1 21.3 ...
 $ Sales   : num  22.1 19.4 13 16.5 17.9 7.2 11.8 13.2 4.9 15.6 ...
  TV      Radio   Newspaper   Sales
 Min.   : 0.70  Min.   : 0.000  Min.   : 0.20  Min.   : 1.00
 1st Qu.: 74.38 1st Qu.: 9.975 1st Qu.: 12.75 1st Qu.: 11.00
 Median : 149.75 Median : 22.900 Median : 25.75 Median : 16.00
 Mean   : 147.04 Mean   : 23.264 Mean   : 30.55 Mean   : 13.12
 3rd Qu.: 218.82 3rd Qu.: 36.525 3rd Qu.: 45.10 3rd Qu.: 19.05
 Max.   : 256.40 Max.   : 49.600 Max.   : 114.00 Max.   : 27.00

Call:
lm(formula = Sales ~ TV, data = advertising)

Residuals:
    Min       1Q   Median       3Q      Max
-4.439  -3.007  -0.465   1.047   4.439
```



Pembahasan :

C. KESIMPULAN

D. LAMPIRAN

NIM : 245410034

Nama : Irvan Cahya Nugraha

Kelas : IF-1

LISTING PRAKTIKUM STATISTIKA MODUL