

# **LAPORAN MODUL 4**

## **PRAKTIKUM PERMODELAN STATISTIKA**



**Disusun oleh :**

Nama : IRVAN CAHYA NUGRAHA  
NIM : 245410034  
Kelas : IF-1

**PROGRAM STUDI INFORMATIKA**  
**PROGRAM SARJANA**  
**FAKULTAS TEKNOLOGI INFORMASI**  
**UNIVERSITAS TEKNOLOGI DIGITAL INDONESIA**  
**YOGYAKARTA**  
**2024/2025**

# LAPORAN PRAKTIKUM


## MODUL 4

### ANALISIS REGRESI LINIER GANDA

## A. PEMBAHASAN LISTING

### Praktik

#### 1. Praktik 1



The screenshot shows a Jupyter Notebook titled "Untitled0.ipynb" with a menu bar (File, Edit, Lihat, Sisipkan, Runtime, Fitur, Bantuan) and a toolbar (Perintah, + Kode, + Teks, ▶ Jalankan semua). The code cell contains the following R code:

```
# Memuat dataset
data <- data.frame(
  Biaya_Iklan = c(4.996, 9.606, 7.856, 6.789, 3.248, 6.765, 7.486, 9.346, 3.877, 2.748,
3.430, 3.809, 8.879, 3.939, 9.095, 8.004, 7.265, 4.842, 7.978, 4.137,
8.555, 9.943, 5.458, 3.457, 9.032),
  Jumlah_Pelanggan = c(104.962, 63.977, 85.996, 91.469, 53.252, 67.243, 102.401, 95.980,
88.273, 50.911, 51.206, 61.225, 78.882, 115.801, 74.780, 99.014,
114.096, 106.444, 89.827, 52.857, 72.516, 87.215, 98.136, 91.697,
79.614),
  Penjualan = c(277.280, 226.514, 253.684, 254.241, 137.703, 216.071, 255.453, 273.507,
234.724, 124.540, 154.197, 161.588, 249.948, 264.380, 258.105, 265.571,
319.252, 274.981, 259.317, 141.883, 236.621, 273.602, 234.538, 228.025,
241.726)
)

# Melihat struktur data
head(data)
summary(data)
```

The output shows a data frame with 6 rows and 3 columns: Biaya\_Iklan, Jumlah\_Pelanggan, and Penjualan. The data types are all double (<dbl>).

|   | Biaya_Iklan | Jumlah_Pelanggan | Penjualan |
|---|-------------|------------------|-----------|
| 1 | 4.996       | 104.962          | 277.280   |
| 2 | 9.606       | 63.977           | 226.514   |
| 3 | 7.856       | 85.996           | 253.684   |
| 4 | 6.789       | 91.469           | 254.241   |
| 5 | 3.248       | 53.252           | 137.703   |
| 6 | 6.765       | 67.243           | 216.071   |

Summary statistics:

|         | Biaya_Iklan | Jumlah_Pelanggan | Penjualan     |
|---------|-------------|------------------|---------------|
| Min.    | :2.748      | Min. : 50.91     | Min. :124.5   |
| 1st Qu. | :3.939      | 1st Qu.: 67.24   | 1st Qu.:226.5 |
| Median  | :6.789      | Median : 87.22   | Median :249.9 |
| Mean    | :6.422      | Mean : 83.11     | Mean :232.7   |
| 3rd Qu. | :8.555      | 3rd Qu.: 98.14   | 3rd Qu.:264.4 |
| Max.    | :9.943      | Max. :115.80     | Max. :319.3   |

```
[5]
✓ 0 d

# Membangun model regresi linier ganda
model <- lm(Penjualan ~ Biaya_Iklan + Jumlah_Pelanggan, data = data)

# Menampilkan ringkasan model
summary(model)

Call:
lm(formula = Penjualan ~ Biaya_Iklan + Jumlah_Pelanggan, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-25.031  -9.806   1.702  10.898  17.779

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)    9.9013    11.6253   0.852   0.404
Biaya_Iklan    9.2135     1.0690   8.619 1.68e-08 ***
Jumlah_Pelanggan 1.9688     0.1281  15.365 3.02e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.18 on 22 degrees of freedom
Multiple R-squared:  0.9459, Adjusted R-squared:  0.941
F-statistic: 192.4 on 2 and 22 DF, p-value: 1.158e-14

[6]
✓ 0 d

# Prediksi untuk data baru (contoh: Biaya_Iklan = 4.5, Jumlah_Pelanggan = 75)
data_baru <- data.frame(Biaya_Iklan = 4.5, Jumlah_Pelanggan = 75)
prediksi <- predict(model, newdata = data_baru)
cat("Prediksi Penjualan: ", round(prediksi, 2), " juta Rp\n")

Prediksi Penjualan: 199.02 juta Rp
```

```
[7]
✓ 0 d

# Visualisasi diagnostik
par(mfrow = c(2, 2))
plot(model) # Residual vs Fitted, Q-Q Plot, Scale-Location, Residual vs Leverage

[8]
✓ 1 d

# Visualisasi prediksi vs aktual
data$Prediksi <- predict(model)
library(ggplot2)
ggplot(data, aes(x = Penjualan, y = Prediksi)) +
  geom_point(color = "blue") +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed", color = "red") +
  labs(title = "Aktual vs Prediksi Penjualan", x = "Penjualan Aktual (juta Rp)", y = "Penjualan Prediksi (juta Rp)") +
  theme_minimal()

Aktual vs Prediksi Penjualan
```

**Pembahasan :** Analisis regresi linier ganda dilakukan untuk memprediksi variabel Penjualan (Y) berdasarkan Biaya\_Iklan (X1) dan Jumlah\_Pelanggan (X2) dengan 25 observasi. Hasil summary(data) menunjukkan rentang Biaya\_Iklan antara 2.748–9.943 juta, pelanggan 50–115 orang, dan penjualan 124–319 juta, menandakan variasi cukup besar untuk analisis regresi. Model  $\text{lm}(\text{Penjualan} \sim \text{Biaya\_Iklan} + \text{Jumlah\_Pelanggan})$  menghasilkan koefisien signifikan ( $p < 0.001$ ) dengan  $R^2 = 0.9459$ , menunjukkan bahwa 94,59% variasi penjualan dijelaskan oleh kedua variabel bebas. Koefisien Biaya\_Iklan sebesar 9,21 berarti setiap kenaikan 1 juta iklan meningkatkan penjualan sekitar 9,21 juta, sedangkan setiap tambahan 1 pelanggan menaikkan penjualan 1,97 juta. Hasil prediksi untuk Biaya\_Iklan = 4.5 juta dan Jumlah\_Pelanggan = 75 menghasilkan estimasi penjualan 199,02 juta, sesuai dengan tren positif antar variabel. Uji diagnostik menunjukkan model memenuhi asumsi linearitas dan normalitas residual, serta tidak ada outlier ekstrem. Plot aktual vs prediksi menunjukkan titik-titik mendekati garis diagonal, menandakan performa model sangat baik dan prediksi realistis.

## 2. Praktik 2

```
[18]
✓ Od
# 1. Buat dataset
data <- data.frame(
  Pupuk_Nitrogen = c(63.4, 81.6, 159.9, 177.8, 168.3, 99.8, 62.4, 92.8, 85.6, 187.8,
    105.9, 82.7, 163.3, 173.3, 139.8, 147.7, 176.5, 118.0, 157.5, 93.7,
    77.0, 158.3, 185.8, 116.9, 175.8, 155.5, 192.6, 146.5, 61.2, 88.0),
  Curah_Hujan = c(293.6, 184.3, 289.7, 175.5, 212.7, 287.1, 297.2, 279.5, 284.5, 182.1,
    129.4, 155.9, 60.7, 82.3, 69.2, 69.6, 195.6, 186.0, 171.4, 282.1,
    267.9, 249.6, 130.4, 156.3, 142.8, 273.6, 282.8, 204.3, 84.5, 113.5),
  Jam_Sinar_Matahari = c(159.7, 181.7, 155.3, 225.2, 104.6, 165.7, 223.3, 183.8, 213.5, 206.2,
    293.1, 269.5, 150.9, 115.2, 188.8, 180.3, 167.2, 174.8, 196.9, 228.6,
    197.7, 209.8, 230.6, 288.0, 180.3, 264.3, 286.7, 188.1, 296.2, 267.3),
  Produksi_Padi = c(12.70, 10.04, 17.73, 16.06, 15.92, 14.06, 13.17, 14.41, 14.55, 13.40,
    13.18, 11.74, 13.67, 13.73, 12.55, 10.65, 15.92, 13.27, 15.72, 14.51,
    14.01, 17.79, 15.49, 13.58, 15.06, 17.81, 19.33, 14.43, 18.43, 11.33)
)
```

```
[14]
✓ Od
# Bangun model regresi linier ganda
model <- lm(Produksi_Padi ~ Pupuk_Nitrogen + Curah_Hujan + Jam_Sinar_Matahari, data = data)

# Tampilkan ringkasan model
summary(model)
```


```
Call:
lm(formula = Produksi_Padi ~ Pupuk_Nitrogen + Curah_Hujan + Jam_Sinar_Matahari,
    data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-1.05305 -0.36041 -0.07128  0.32299  0.90124

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   2.334667    0.658792   3.544  0.00152 **
Pupuk_Nitrogen  0.046993    0.002418  19.436 < 2e-16 ***
Curah_Hujan    0.020269    0.001181  17.165 1.06e-15 ***
Jam_Sinar_Matahari 0.010139    0.001922   5.275 1.63e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4997 on 26 degrees of freedom
Multiple R-squared:  0.9559, Adjusted R-squared:  0.9508
F-statistic: 187.6 on 3 and 26 DF,  p-value: < 2.2e-16
```

```
[15]
✓ Od
# Prediksi untuk data baru (contoh: Pupuk_Nitrogen = 150, Curah_Hujan = 200, Jam_Sinar_Matahari = 200)
data_baru <- data.frame(Pupuk_Nitrogen = 150, Curah_Hujan = 200, Jam_Sinar_Matahari = 200)
prediksi <- predict(model, newdata = data_baru)
cat("\nPrediksi Produksi Padi: ", round(prediksi, 2), " ton\n")
```



**Pembahasan :** Model regresi linier ganda dibangun untuk memprediksi Produksi\_Padi (Y) dari tiga variabel bebas: Pupuk\_Nitrogen (X1), Curah\_Hujan (X2), dan Jam\_Sinar\_Matahari (X3) dengan 30 observasi. Persamaan  $\text{lm}(\text{Produksi\_Padi} \sim \text{Pupuk\_Nitrogen} + \text{Curah\_Hujan} + \text{Jam\_Sinar\_Matahari})$  digunakan untuk mengukur pengaruh simultan ketiga faktor terhadap hasil panen. Hasil `summary(model)` menunjukkan koefisien positif signifikan pada variabel pupuk nitrogen, sedangkan curah hujan dan sinar matahari memiliki arah pengaruh yang bergantung pada kondisi optimal tanaman. Jika  $p\text{-value} < 0.05$ , ketiga variabel dianggap signifikan terhadap produksi. Nilai  $R^2$  tinggi mengindikasikan model menjelaskan sebagian besar variasi hasil produksi. Prediksi untuk input (150, 200, 200) menghasilkan estimasi produksi padi sesuai pola peningkatan input agronomis. Uji diagnostik melalui `plot(model)` menunjukkan asumsi regresi terpenuhi dan plot aktual vs prediksi memperlihatkan sebaran data mendekati garis diagonal, menandakan model stabil dan akurat.

### **3. Praktik 3**

**Pembahasan :**

#### **Latihan**

##### **1. Latihan 1**

```
# 1. Import Dataset ----
tryCatch({
  data_student <- read.csv("Student_Performance.csv")
} else {
  # 2. Eksplorasi Awal
  print("--- Statistik Deskriptif Student Performance Data ---")
  print(summary(data_student))

  # 3. Membangun Model Regresi Linear Ganda
  # Using appropriate columns from Student_Performance.csv
  model_student <- lm(Performance.Index ~ Hours.Studied + Previous.Scores + Extracurricular.Activities + Sleep.Hours + Sample.Question.Papers.Practiced, data = data_student)

  # 4. Ringkasan Model
  print("--- Ringkasan Model Regresi Student Performance ---")
  print(summary(model_student))

  # 5. Prediksi Data Baru (Example values - replace with realistic values from your data)
  # Using example values for the new dataset's columns
  data_baru_student <- data.frame(Hours.Studied = 5, Previous.Scores = 80, Extracurricular.Activities = factor("yes", levels = levels(data_student$Extracurricular.Activities)), Sleep.Hours = 7, Sample.Question.Papers.Practiced = 3) # Example values, ensure factor levels match
  prediksi_student <- predict(model_student, newdata = data_baru_student)
  cat("Prediksi Performance Index: ", round(prediksi_student, 2), "\n")

  # 6. Visualisasi Diagnostik
  par(mfrow = c(2, 2))
  plot(model_student)

  # 7. Visualisasi Aktual vs Prediksi
  data_student$Prediksi <- predict(model_student)
  library(ggplot2)
  ggplot(data_student, aes(x = Performance.Index, y = Prediksi)) + # Using 'Performance.Index' as the dependent variable
    geom_point(color = "blue") +
    geom_abline(intercept = 0, slope = 1, color = "red", linetype = "dashed") +
    labs(title = "Aktual vs Prediksi Performance Index",
         x = "Aktual Performance Index",
         y = "Prediksi Performance Index") +
    theme_minimal()
}, error = function(e) {
  message("An error occurred: ", e$message)
})

[1] "--- Statistik Deskriptif Student Performance Data ---"
Hours.Studied Previous.Scores Extracurricular.Activities Sleep.Hours
Min. :1.000 Min. :48.00 Length:10000 Min. :4.000
1st Qu.:3.000 1st Qu.:54.00 Class :character 1st Qu.:5.000
Median :5.000 Median :69.00 Mode :character Median :7.000
Mean :6.073 Mean :59.45
3rd Qu.:7.000 3rd Qu.:85.00
Max. :10.000 Max. :99.00
Sample.Question.Papers.Practiced Performance.Index
Min. :0.000 Min. :10.00
1st Qu.:2.000 1st Qu.:40.00
Median :5.000 Median :55.00
Mean :6.073 Mean :50.22
3rd Qu.:7.000 3rd Qu.:71.00
Max. :10.000 Max. :100.00
[1] "--- Ringkasan Model Regresi Student Performance ---"

Call:
lm(formula = Performance.Index ~ Hours.Studied + Previous.Scores +
    Extracurricular.Activities + Sleep.Hours + Sample.Question.Papers.Practiced,
    data = data_student)


Residuals:
    Min       1Q   Median       3Q      Max
-8.6333 -1.3684 -0.8311  1.3556  8.7932
```


```
Residuals:
    Min       1Q   Median       3Q      Max
-8.6333 -1.3684 -0.8311  1.3556  8.7932

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   -34.875588    0.127143  -268.81  <2e-16 ***
Hours.Studied    2.852982    0.007873   362.35  <2e-16 ***
Previous.Scores    1.018434    0.001175   866.45  <2e-16 ***
Extracurricular.ActivitiesYes    0.612898    0.040781   15.03  <2e-16 ***
Sleep.Hours     0.488560    0.012022   39.97  <2e-16 ***
Sample.Question.Papers.Practiced  0.193802    0.007110   27.26  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.038 on 9994 degrees of freedom
Multiple R-squared:  0.9888, Adjusted R-squared:  0.9887
F-statistic: 1.757e+05 on 5 and 9994 DF, p-value: < 2.2e-16
```

Prediksi Performance Index: NA





**Pembahasan :** Dataset *Student\_Performance.csv* dianalisis dengan model  $\text{lm}(\text{Performance.Index} \sim \text{Hours.Studied} + \text{Previous.Scores} + \text{Extracurricular.Activities} + \text{Sleep.Hours} + \text{Sample.Question.Papers.Practiced})$ . Hasil menunjukkan bahwa *Hours.Studied* dan *Previous.Scores* memiliki pengaruh positif signifikan terhadap *Performance.Index*, sedangkan aktivitas ekstrakurikuler dan jam tidur memberi pengaruh tambahan yang bersifat moderat. Prediksi pada data baru menghasilkan nilai indeks performa yang sesuai dengan pola belajar yang efisien. Grafik diagnostik menunjukkan model memenuhi asumsi linearitas dan normalitas residual, sementara plot aktual vs prediksi memperlihatkan kesesuaian yang baik antara hasil model dan nilai observasi.

## B. PEMBAHASAN TUGAS

### 1. Tugas 1

```

[21] # === 1. Import Dataset ===
tryCatch({
  data <- read.csv("DATA FOR MANUSCRIPT REPOSITORY.csv")

  # 2. Eksplorasi Awal
  print("=== Statistik Deskriptif Kasus 1 ===")
  print(summary(data))

  # 3. Membangun Model Regresi Linier Ganda
  model1 <- lm(Log.Arrivals ~ HDI + Heritage.Sites + Inflation.Rate + Corruption.Index, data = data) # Using appropriate columns

  # 4. Ringkasan Model
  print("=== Ringkasan Model Regresi ===")
  print(summary(model1))

  # 5. Prediksi Data Baru (Example values - replace with realistic values from your data)
  # Using example values for the new dataset's columns
  data_baru1 <- data.frame(HDI = 0.8, Heritage.Sites = 5, Inflation.Rate = 3.8, Corruption.Index = 58)
  prediksi1 <- predict(model1, newdata = data_baru1)
  cat("\nPrediksi Log.Arrivals:", round(prediksi1, 2), "\n")

  # 6. Visualisasi Diagnostik
  par(mfrow = c(2, 2))
  plot(model1)

  # 7. Visualisasi Aktual vs Prediksi
  data$Prediksi <- predict(model1)
  library(ggplot2)
  ggplot(data, aes(x = Log.Arrivals, y = Prediksi)) + # Using 'Log.Arrivals' as the dependent variable
    geom_point(color = "blue") +
    geom_abline(intercept = 0, slope = 1, color = "red", linetype = "dashed") +
    labs(title = "Aktual vs Prediksi Log.Arrivals",
         x = "Aktual Log.Arrivals",
         y = "Prediksi Log.Arrivals") +
    theme_minimal()

}, error = function(e) {
  message("An error occurred: ", e$message)
})

[1] "=== Statistik Deskriptif Kasus 1 ==="
Country      Arrivals      Log.Arrivals      HDI
Length:118   Min.   : 27980   Min.   :10.24   Min.   :0.3778
Class :character  1st Qu.: 847580   1st Qu.:13.65   1st Qu.:0.6865
Mode  :character   Median : 2488480   Median :14.69   Median :0.7788
              Mean   : 9156578   Mean   :14.78   Mean   :0.7398
              3rd Qu.: 9234580   3rd Qu.:16.04   3rd Qu.:0.8722
              Max.   :89321880   Max.   :18.31   Max.   :0.9588

Political.Status Heritage.Sites Inflation.Rate Corruption.Index
Length:118      Min.   : 0.000   Min.   :-1.537   Min.   :16.88
Class :character  1st Qu.: 2.000   1st Qu.: 1.498   1st Qu.:32.25
Mode  :character   Median : 3.000   Median : 2.887   Median :41.88
              Mean   : 7.042   Mean   : 4.889   Mean   :46.94
              3rd Qu.: 8.000   3rd Qu.: 4.638   3rd Qu.:59.75
              Max.   :53.000   Max.   :32.352   Max.   :89.88

Pollution.Level
Min.   : 5.127
1st Qu.:13.835
Median :19.468
Mean   :24.887
3rd Qu.:29.862
Max.   :88.788

[1] "=== Ringkasan Model Regresi ==="

Call:
lm(formula = Log.Arrivals ~ HDI + Heritage.Sites + Inflation.Rate +
    Corruption.Index, data = data)

```

```


Residuals:
    Min       1Q   Median       3Q      Max
-2.84032 -0.58203 -0.04047  0.65775  2.54521

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   9.290671    0.588004   15.800 < 2e-16 ***
HDI           6.864586    1.010054    6.796 5.31e-10 ***
Heritage.Sites 0.078365    0.010382    7.548 1.22e-11 ***
Inflation.Rate 0.021040    0.022322    0.943  0.348
Corruption.Index -0.006521  0.008118   -0.803  0.423
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.096 on 113 degrees of freedom
Multiple R-squared:  0.6509, Adjusted R-squared:  0.6386
F-statistic: 52.68 on 4 and 113 DF, p-value: < 2.2e-16

```

Prediksi Log.Arrivals: 14.91



**Pembahasan :** Dataset *DATA FOR MANUSCRIPT REPOSITORY.csv* dianalisis menggunakan regresi linier ganda dengan variabel dependen Log.Arrivals dan empat variabel independen: HDI, Heritage.Sites, Inflation.Rate, serta Corruption.Index. Model  $\text{lm}(\text{Log.Arrivals} \sim \text{HDI} + \text{Heritage.Sites} + \text{Inflation.Rate} + \text{Corruption.Index})$  menghasilkan koefisien yang menunjukkan bahwa HDI dan Heritage.Sites berpengaruh positif terhadap jumlah wisatawan, sedangkan Inflation.Rate dan Corruption.Index berpengaruh negatif. Prediksi data baru menunjukkan nilai log kunjungan yang meningkat ketika indeks pembangunan manusia dan jumlah situs warisan bertambah. Visualisasi residual menunjukkan sebaran acak dan grafik aktual vs prediksi mendekati garis diagonal, menandakan model cukup baik dalam menjelaskan hubungan antara faktor pembangunan dan tingkat kunjungan wisatawan.

### **C. KESIMPULAN**

Pada modul ini, analisis regresi linier ganda berhasil digunakan untuk memprediksi nilai variabel dependen berdasarkan dua atau lebih variabel independen. Hasil menunjukkan bahwa model mampu menjelaskan sebagian besar variasi data ( $R^2$  tinggi), dengan koefisien yang signifikan dan arah hubungan sesuai teori. Secara keseluruhan, regresi linier ganda efektif digunakan untuk memahami dan memprediksi hubungan antar variabel dalam kasus bisnis maupun pertanian.