

LAPORAN MODUL 5

PRAKTIKUM PERMODELAN STATISTIKA



Disusun oleh :

Nama : IRVAN CAHYA NUGRAHA
NIM : 245410034
Kelas : IF-1

PROGRAM STUDI INFORMATIKA
PROGRAM SARJANA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TEKNOLOGI DIGITAL INDONESIA
YOGYAKARTA
2024/2025

LAPORAN PRAKTIKUM


MODUL 5


REGRESI DENGAN DUMMY VARIABEL

A. PEMBAHASAN LISTING

Praktik


1. Praktik 1






Pembahasan : Pada Kasus 1, dilakukan analisis regresi linier dengan variabel numerik Pengalaman dan variabel dummy JenisKelamin untuk memprediksi Gaji. Variabel *JenisKelamin* dikonversi menjadi faktor sehingga R otomatis membuat dummy dengan kategori referensi “Laki-laki”. Hasil model menunjukkan bahwa pengalaman kerja berpengaruh positif terhadap gaji, sedangkan jenis kelamin tidak signifikan secara statistik. Nilai R^2 sebesar 0.7959 menunjukkan model mampu menjelaskan sekitar 79,6% variasi gaji. Model valid secara keseluruhan, ditunjukkan oleh nilai F-statistic signifikan, meski variabel dummy tidak signifikan secara individual.

2. Praktikum 2





Pembahasan : Pada Kasus 2, regresi linier ganda digunakan untuk memprediksi Penjualan berdasarkan Iklan, Karyawan, dan variabel kategorikal TipeToko. R secara otomatis membuat dua dummy variabel untuk kategori *Kecil* dan *Sedang* dengan *Besar* sebagai referensi. Hasil analisis menunjukkan bahwa jumlah karyawan memiliki pengaruh signifikan terhadap penjualan, sedangkan pengeluaran iklan dan tipe toko tidak signifikan. Nilai $R^2 = 0.9649$ menandakan model memiliki kemampuan prediksi yang sangat baik. Secara keseluruhan, model signifikan, dengan RMSE rendah yang menunjukkan akurasi prediksi tinggi.

Latihan

1. Latihan 1

```

# Memuat dataset dari file day.csv
data_day <- read.csv("day.csv")

# Memeriksa struktur data
str(data_day)

# Membuat model regresi linier ganda
# Ganti 'variabel_respon' dan 'variabel_prediktor' sesuai dengan nama kolom di day.csv
# Contoh: model_day <- lm(cnt ~ temp + hum + windspeed, data = data_day)
# Anda perlu menyesuaikan formula regresi berdasarkan variabel yang relevan di dataset day.csv
model_day <- lm(cnt ~ temp + hum + windspeed + season + yr + mnth + holiday + weekday + workingday + weathersit, data = data_day)

# Menampilkan ringkasan model
summary(model_day)

# Visualisasi diagnostik untuk model_day
par(mfrow = c(2, 2))
plot(model_day)


# Menghitung RMSE
prediksi_all_day <- predict(model_day, data_day)
rmse_day <- sqrt(mean((data_day$cnt - prediksi_all_day)^2))
cat("RMSE day.csv: ", rmse_day, "\n")

# Visualisasi hubungan antar variabel (Contoh: cnt vs temp, dengan warna berdasarkan season)
# Anda bisa mengganti 'temp' dan 'season' dengan variabel lain yang relevan dari day.csv
plot(data_day$temp, data_day$cnt, col = data_day$season,
     pch = 19, main = "Cnt vs Temp berdasarkan Season",
     xlab = "Temperature", ylab = "Cnt")
legend("topleft", legend = levels(as.factor(data_day$season)), col = 1:length(levels(as.factor(data_day$season))), pch = 19)

# Contoh Prediksi untuk data baru (misal: temp=20, hum=60, windspeed=15, season=1, yr=1, mnth=6, holiday=0, weekday=3, workingday=1, weathersit=2)
# Pastikan level faktor sesuai dengan data training
new_data_day <- data.frame(temp = 20, hum = 60, windspeed = 15, season = 1, yr = 1, mnth = 6, holiday = 0, weekday = 3, workingday = 1, weathersit = 2)
prediksi_day <- predict(model_day, newdata = new_data_day)
cat("Prediksi cnt untuk kondisi spesifik: ", prediksi_day, "\n")

'data.frame': 730 obs. of 16 variables:
 $ instant : int 1 2 3 4 5 6 7 8 9 10 ...
 $ dteday : chr "01-01-2018" "02-01-2018" "03-01-2018" "04-01-2018" ...
 $ season : int 1 1 1 1 1 1 1 1 1 1 ...
 $ yr : int 0 0 0 0 0 0 0 0 0 0 ...
 $ mnth : int 1 1 1 1 1 1 1 1 1 1 ...
 $ holiday : int 0 0 0 0 0 0 0 0 0 0 ...
 $ weekday : int 6 0 1 2 3 4 5 6 0 1 ...
 $ workingday : int 0 0 1 1 1 1 1 0 0 1 ...
 $ weathersit : int 2 2 1 1 1 1 2 2 1 1 ...
 $ temp : num 14.11 14.9 8.05 8.2 9.31 ...
 $ atemp : num 18.18 17.69 9.47 10.61 11.46 ...
 $ hum : num 80.6 69.6 43.7 59 43.7 ...
 $ windspeed : num 10.7 16.7 16.6 10.7 12.5 ...
 $ casual : int 331 131 120 108 82 88 148 68 54 41 ...

```



Pembahasan : Dataset *day.csv* berisi 730 observasi penyewaan sepeda harian dengan variabel target *cnt*. Model regresi linier ganda dibangun menggunakan variabel prediktor seperti *temp*, *hum*, *windspeed*, *season*, *yr*, *mnth*, *holiday*, *weekday*, *workingday*, dan *weathersit*.

Hasil analisis menunjukkan bahwa suhu (*temp*), musim (*season*), dan tahun (*yr*) berpengaruh positif dan signifikan terhadap jumlah penyewaan, yang berarti semakin tinggi suhu dan semakin baru tahunnya, maka jumlah penyewaan cenderung meningkat. Sebaliknya, *hum* (kelembapan), *windspeed*, dan *weathersit* (kondisi cuaca) berpengaruh negatif, artinya cuaca lembab, berangin, atau buruk menurunkan minat pengguna.

Nilai *Adjusted R*² = 0.7968 menunjukkan bahwa sekitar 79,68% variasi jumlah penyewaan dapat dijelaskan oleh variabel dalam model, dengan *F-statistic* yang sangat signifikan ($p < 0.001$). Nilai RMSE sekitar 866 mengindikasikan ketepatan prediksi yang cukup baik. Hasil prediksi untuk kondisi tertentu (*temp*=20, *hum*=60, dll) menghasilkan *cnt* ≈ 4355.37 , yang sejalan dengan pola hubungan positif antara suhu dan penyewaan. Secara keseluruhan, model ini kuat dan reliabel untuk estimasi tren penyewaan sepeda berdasarkan faktor lingkungan dan kalender.

B. PEMBAHASAN TUGAS

1. Tugas 1

```
# Memuat dataset dari file reg_data.csv
data_reg <- read.csv("reg_data.csv")

# Memeriksa struktur data
str(data_reg)

# Membuat model regresi linier ganda
# Ganti 'variabel_respon' dan 'variabel_prediktor' sesuai dengan nama kolom di reg_data.csv
# Anda perlu menyesuaikan formula regresi berdasarkan variabel yang relevan di dataset reg_data.csv
# Contoh: model_reg <- lm(Response ~ Predictor1 + Predictor2, data = data_reg)
model_reg <- lm(max90 ~ DRAIN_SQOM + PPTAVG_BASIN + T_AVG_BASIN + RH_BASIN + MAR_PPT7100_CM + RRMEDIAN, data = data_reg)

# Menampilkan ringkasan model
summary(model_reg)

# Visualisasi diagnostik untuk model_reg
par(mfrow = c(2, 2))
plot(model_reg)

# Menghitung RMSE
prediksi_all_reg <- predict(model_reg, data_reg)
rmse_reg <- sqrt(mean((data_reg$max90 - prediksi_all_reg)^2))
cat("RMSE reg_data.csv: ", rmse_reg, "\n")

# Visualisasi hubungan antar variabel (Contoh: max90 vs DRAIN_SQOM)
# Anda bisa mengganti 'DRAIN_SQOM' dengan variabel prediktor lain yang relevan
plot(data_reg$DRAIN_SQOM, data_reg$max90,
     pch = 19, main = "Max90 vs DRAIN_SQOM",
     xlab = "DRAIN_SQOM", ylab = "Max90")

# Contoh Prediksi untuk data baru (misal: DRAIN_SQOM=1000, PPTAVG_BASIN=100, T_AVG_BASIN=5, RH_BASIN=70, MAR_PPT7100_CM=8, RRMEDIAN=0.2)
new_data_reg <- data.frame(DRAIN_SQOM=1000, PPTAVG_BASIN=100, T_AVG_BASIN=5, RH_BASIN=70, MAR_PPT7100_CM=8, RRMEDIAN=0.2)
prediksi_reg <- predict(model_reg, newdata = new_data_reg)
cat("Prediksi max90 untuk kondisi spesifik: ", prediksi_reg, "\n")


'data.frame': 293 obs. of 9 variables:
 $ STAID      : int  1013500 1022500 1030500 1031500 1047000 1052500 1055000 1057000 1073000 1078000 ...
 $ max90      : num  12440 6343 22600 12200 14730 ...
 $ DRAIN_SQOM : num  2253 574 3676 769 909 ...
 $ PPTAVG_BASIN : num  97.4 120.1 108.2 118 118.9 ...
 $ T_AVG_BASIN : num  3 5.95 4.82 4.14 3.99 ...
 $ T_AVG_SITE  : num  3 6.3 5.4 4.9 5.6 3.7 4.9 6.1 8.3 6.5 ...
 $ RH_BASIN    : num  71.7 68.8 69.6 68.5 68.7 ...
 $ MAR_PPT7100_CM : num  6.32 10.68 8.69 9.54 9.5 ...
 $ RRMEDIAN    : num  0.215 0.162 0.139 0.285 0.202 ...

Call:
lm(formula = max90 ~ DRAIN_SQOM + PPTAVG_BASIN + T_AVG_BASIN +
    RH_BASIN + MAR_PPT7100_CM + RRMEDIAN, data = data_reg)

Residuals:
    Min       1Q   Median       3Q      Max
-31709  -4840  -1560   2861   57431

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.256e+04  7.051e+03  -1.783  0.075839 .
DRAIN_SQOM   2.040e+00  2.487e-01  8.202  8.1e-15 ***
PPTAVG_BASIN 3.544e+01  3.452e+01  1.027  0.305467
T_AVG_BASIN  4.161e+02  1.202e+02  3.462  0.000618 ***
RH_BASIN     9.578e+01  1.174e+02  0.816  0.415264
MAR_PPT7100_CM 2.979e+02  2.451e+02  1.215  0.225286
RRMEDIAN     3.918e+03  3.967e+03  0.988  0.324136
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9028 on 286 degrees of freedom
Multiple R-squared:  0.2914, Adjusted R-squared:  0.2765
F-statistic: 19.6 on 6 and 286 Df, p-value: < 2.2e-16
RMSE reg_data.csv: 8919.525
Prediksi max90 untuk kondisi spesifik: 4972.507
```



Pembahasan : Dataset *reg_data.csv* berisi 293 observasi hidrologi dengan variabel max90 sebagai respon. Model $\text{max90} \sim \text{DRAIN_SQKM} + \text{PPTAVG_BASIN} + \text{T_AVG_BASIN} + \text{RH_BASIN} + \text{MAR_PPT7100_CM} + \text{RRMEDIAN}$ menunjukkan bahwa DRAIN_SQKM dan T_AVG_BASIN signifikan positif terhadap max90, sedangkan variabel lain tidak signifikan. Nilai Adjusted $R^2 = 0.2765$ dan $\text{RMSE} \approx 8919$ menunjukkan akurasi model sedang. Prediksi contoh menghasilkan $\text{max90} \approx 4972.51$.

C. KESIMPULAN

Modul ini memperlihatkan penerapan regresi linier ganda untuk dua kasus berbeda: data penyewaan sepeda dan data hidrologi. Pada kasus pertama, model berhasil menjelaskan hampir 80% variasi data dan menghasilkan prediksi yang akurat. Pada kasus kedua, model hanya mampu menjelaskan sebagian kecil variasi, menunjukkan bahwa hubungan antar variabel tidak sepenuhnya linier atau masih ada faktor lain yang belum dimasukkan.

Secara umum, analisis ini menegaskan pentingnya pemilihan variabel yang relevan, pengujian asumsi model, serta evaluasi metrik seperti R^2 dan RMSE agar model regresi tidak hanya signifikan secara statistik tetapi juga memiliki daya prediksi yang kuat dan realistis.

D. LAMPIRAN

NIM : 245410034

Nama : Irvan Cahya Nugraha

Kelas : IF-1

LISTING PRAKTIKUM STATISTIKA MODUL